

TECNICATURA UNIVERSITARIA EN ADMINISTRACIÓN

ESTADÍSTICA

UNIDAD III

REGRESIÓN Y CORRELACIÓN LINEAL

PROFESOR:

Daniela Arias

UNIDAD III: REGRESIÓN Y CORRELACIÓN LINEAL

PRESENTACIÓN

En esta unidad veremos: Regresión y correlación lineal: El método de Mínimos Cuadrados. Análisis de Regresión. Coeficiente de Correlación. Análisis de Residuos.

OBJETIVOS

QUE LOS PARTICIPANTES LOGREN:

- Reconocer el significado de la regresión.
- Construir la recta de regresión lineal.
- Interpretar el resultado del error en la regresión.
- Analizar gráficos de residuos.

TEMARIO

- Regresión y Correlación Lineal
- Ajuste por mínimos cuadrados
- Coeficiente de correlación y determinación
- Análisis de residuos.



1. REGRESION Y CORRELACION LINEAL

Muy a menudo se presentan situaciones en las que es de gran interés estudiar la relación entre dos variables. Lógicamente los datos de estudio dejan de ser univariados (una única observación por cada unidad elemental de la muestra), pasando nuestra población de estudio a ser bivariada (dos observaciones por cada unidad elemental).

Por ejemplo podemos observar el peso y la edad de cada individuo, el gasto de una empresa y sus ingresos, etc.

El análisis de regresión involucra el estudio de la relación entre dos variables **cuantitativas**. En general interesa:

- Investigar si existe una asociación entre las dos variables testeando la hipótesis de independencia estadística.
- Estudiar la fuerza de la asociación, a través de una medida de asociación denominada coeficiente de correlación.
- Estudiar la forma de la relación.

Usando los datos propondremos un modelo para la relación y a partir de ella será posible predecir el valor de una variable a partir de la otra.

Para ello proponemos un modelo que relaciona una variable dependiente (Y) con una variable independiente (X).

Llamaremos **modelo matemático** a la función matemática que proponemos como forma de relación entre la variable dependiente Y (variable de respuesta) y la variable independientes X (variable regresora). La función más simple para la relación entre dos variables es la **función lineal**:

$$Y = a + b X$$

Esta expresión es una aproximación de la verdadera relación entre X e Y.

Para un dado valor de X el modelo predice un cierto valor para Y .

Mientras mejor sea la predicción, mejor es el modelo para explicar el fenómeno.

Nuestro modelo será un **modelo estadístico** porque permite la incorporación de un **componente aleatorio** en la relación.

En consecuencia, las predicciones obtenidas a través de modelos estadísticos tendrán asociado un error de predicción.

Por ejemplo, la relación de la altura con la edad en niños. Niños de la misma edad seguramente no tendrán la misma altura. Sin embargo, a través de un modelo estadístico es posible concluir que la altura aumenta con la edad. Es más, podríamos predecir la altura de un niño de cierta edad y asociarle **un error de predicción** que tiene en cuenta: **errores de medición y variabilidad entre individuos**.

En problemas biológicos, trabajando en “condiciones ideales” es posible evitar los errores de medición, pero no la variabilidad individual, por eso es indispensable incluir el componente aleatorio en los modelos estadísticos.

En este curso trataremos sobre Regresión Lineal. Haremos énfasis en este tipo de modelos porque son de amplia aplicación y más simples de implementar.


Regresión Lineal simple:

Supongamos que el consumo (Y) y el ingreso (X) para los últimos 4 años (en millones de pesos) fueron los siguientes:

Año	X	Y
1	5	3
2	6	4
3	8	5
4	9	8
$N=4$	$\bar{X} = 7$	$\bar{Y} = 5$

Se desea probar la hipótesis de que el consumo depende de las variaciones que experimenta el ingreso. Los valores apareados de X e Y se pueden representar en un gráfico llamado diagrama de dispersión.

El objetivo de este diagrama es el de sugerir la forma funcional del modelo estadístico tal como se ve en la siguiente figura:



Se observa que el diagrama de dispersión de la figura anterior sugiere una relación lineal con pendiente positiva.

También se puede observar que una línea recta no puede pasar por todos los puntos en el diagrama, esto significa que, al no caer todos los puntos alineados sobre una misma recta, no toda la variación de Y puede ser explicada por la variación de X.

Esto nos conduce naturalmente a la aplicación de métodos estadísticos. La predicción de Y para un valor dado de X es un proceso inferencial y se requiere conocer las propiedades del error de la predicción.

Como dijimos, parece razonable pensar que la relación **ingreso-consumo** es

aparentemente lineal. Podemos proponer el modelo: $Consumo = \beta_0 + \beta_1 * Ingreso +$

error


Es decir: $Y_i = \beta_0 + \beta_1 * X_i + \varepsilon_i$

Podríamos intentar ajustar una recta “a ojo, tendríamos por ejemplo las rectas:

$$y_i = -\frac{1}{3} + \frac{2}{3} * x_i$$

$$y_i = -4 + \frac{4}{3} * x_i$$

¿Cuál recta es “mejor”? ¿Cómo decidir? Veamos los gráficos.



Para decidir cuál de las dos rectas ajusta mejor estos datos se considera una medida de cuán lejos está cada dato de la recta propuesta o sea se analizan lo que llamamos **RESIDUOS**

Residuos = Y observado – Y ajustado

La mejor recta sería aquella que minimice la suma de las distancias al cuadrado de los puntos a la recta.

Afortunadamente no es necesario probar con diferentes rectas cuál de ellas es la que produce la menor suma de cuadrados, ya que es posible encontrar analíticamente las expresiones para $\hat{\beta}_0$ y $\hat{\beta}_1$. Recordemos que $\hat{\beta}_0$ es la ordenada al origen de la recta de aproximación y $\hat{\beta}_1$ es la pendiente de dicha recta.

El método para encontrar la recta que mejor se ajuste a los datos se conoce como **método de mínimos cuadrados**.

2. AJUSTE POR MÍNIMOS CUADRADOS

Como dijimos con este método obtendremos una recta que mejor se ajusta a los datos de la muestra, en el sentido que hace mínima la suma de los cuadrados de las diferencias entre cada observación y su estimación sobre la recta.

La recta de regresión será: $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 * X_i$

Dijimos que los residuos $e_i = Y_i - \hat{Y}_i$ entonces $\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 * x_i)^2$

El método consiste en que los valores de $\hat{\beta}_0$ y $\hat{\beta}_1$ deben escogerse de tal forma que hagan a la $\sum_{i=1}^n e_i^2$, lo más chica posible. Una condición necesaria para esto es que las derivadas parciales de la suma con respecto a $\hat{\beta}_0$ y $\hat{\beta}_1$ deberán ser iguales a cero, con lo cual podemos escribir:

$$\frac{\partial}{\partial \hat{\beta}_0} \left(\sum_{i=1}^n e_i^2 \right) = -2 \sum_{i=1}^n (y_i - 1 - \hat{\beta}_1 * x_i) = 0$$

$$\frac{\partial}{\partial \hat{\beta}_1} \left(\sum_{i=1}^n e_i^2 \right) = -2 \sum_{i=1}^n x_i * (y_i - \hat{\beta}_0 - x_i) = 0$$

Simplificando estas dos ecuaciones se obtiene un sistema de ecuaciones llamadas normales para hallar la recta.

$$\text{Así la pendiente se calcula como: } \hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X}) * (Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\text{y la ordenada: } \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 * \bar{X}$$

Para nuestro ejemplo **Ingreso-consumo**, los estimadores por mínimos cuadrados para

β_0 y β_1 serian:


$$\hat{\beta}_1 = \frac{\sum_{i=1}^4 (X_i - \bar{X}) * (Y_i - \bar{Y})}{\sum_{i=1}^4 (X_i - \bar{X})^2} = \frac{(5-7)(3-5) + (6-7)(4-5) + (8-7)(5-5) + (9-7)(8-5)}{(5-7)^2 + (6-7)^2 + (8-7)^2 + (9-7)^2}$$

La **recta ajustada** para nuestros datos es: $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 * X_i = -2.7 + 1.1 * X_i$

Obsérvese que $\hat{\beta}_1$ tiene signo positivo, lo cual es bueno porque corrobora la teoría económica de que a medida que aumenta el ingreso (X) también aumenta el consumo (Y).

El gráfico de esta recta en el diagrama de dispersión es:

$$y = -2.7 + 1.1 * x$$



Ingresos

El método de mínimos cuadrados permite estimar una recta a partir de un conjunto de datos.


Si estos datos son una muestra “adecuada” de una población, la recta nos permite extender resultados a dicha población. Ciertas características de los datos podrían invalidar los resultados del método.

Ejemplo :

Vamos a tomar el ejemplo expuesto y realizarlo con Excel.


Año	X	Y
1	5	3
2	6	4
3	8	5
4	9	8
N=4	$\bar{X} = 7$	$\bar{Y} = 5$

Lo primero es MARCAR LOS VALORES DE X y de Y. Ir a INSERTAR/ GRÁFICOS /DISPERSIÓN:




Automáticamente realizará el gráfico de dispersión. Ahora debemos buscar la línea de tendencia, la ecuación y el R cuadrado. Para ello nos posicionamos sobre el gráfico marcándolo y buscamos dentro de AGREGAR

ELEMENTO DE GRÁFICO / LÍNEA DE TENDENCIA / LINEAL / MAS OPCIONES DE LÍNEA DE TENDENCIA / AL FINAL MARCAMOS PRESENTAR ECUACIÓN EN EL GRÁFICO Y PRESENTAR VALOR DE R CUADRADO EN EL GRÁFICO



Resultado Final:



Aclaración: en el próximo capítulo veremos el significado del R^2 .

3. COEFICIENTE DE CORRELACIÓN Y DETERMINACIÓN

Con alguna frecuencia el interés que hay en la relación entre dos variables X e Y se concentra en determinar si están o no relacionadas, y en caso afirmativo, averiguar qué tan fuerte es la relación.

La técnica analítica apropiada que se emplea en esta situación es el análisis de correlación; es decir que se utiliza cuando se quiere conocer el grado de asociación entre las variables.

Generalmente se utiliza **el coeficiente r de Pearson**, que es una medida de la dispersión de los datos alrededor de la recta de regresión. Es una medida cuantitativa de la fuerza de la relación. Proporciona tres datos principales:

- La existencia o no de una relación entre las variables
- La dirección de la relación, si es positiva o negativa
- El grado de esa relación

Es un coeficiente que varía entre -1 y 1. Si su valor es cercano a cero, indica la inexistencia de correlación. A medida que se va acercando a -1 o 1, la correlación será más fuerte.

La aplicación de este coeficiente supone el cumplimiento de determinadas condiciones:

- La distribución conjunta de X e Y debe ser normal
- La relación entre X e Y es en cierto sentido, lineal
- Debe haber homogeneidad entre las varianzas correspondientes a X e Y

El coeficiente se calcula con la ecuación:

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X}) * (Y_i - \bar{Y})}{n * S_x * S_y}$$

Donde S_x y S_y son las desviaciones estándares de las X's y de las Y's respectivamente.

$$S_x = \sqrt{\frac{\sum_{i=1}^n X_i^2}{N} - \bar{X}^2}$$

$$S_y = \sqrt{\frac{\sum_{i=1}^n Y_i^2}{N} - \bar{Y}^2}$$

Continuando con nuestro análisis inicial, el coeficiente de correlación de Pearson es:

$$r = \frac{\sum_{i=1}^4 (X_i - \bar{X}) * (Y_i - \bar{Y})}{n * S_x * S_y} = \frac{(5-7)(3-5) + (6-7)(4-5) + (8-7)(5-5) + (9-7)(8-5)}{4 * 1.58 * 1.87} = 0.93$$

$$S_y = \sqrt{\frac{\sum_{i=1}^n Y_i^2}{N} - \bar{Y}^2} = \sqrt{\frac{3^2 + 4^2 + 5^2 + 8^2}{4} - 5^2} = 1.87$$

$$S_x = \sqrt{\frac{\sum_{i=1}^4 X_i^2}{N} - \bar{X}^2} = \sqrt{\frac{5^2 + 6^2 + 8^2 + 9^2}{4} - 7^2} = 1.58$$

Por lo tanto podemos decir que existe una alta correlación de carácter positivo entre X e Y. Ya sabíamos que iba a ser positiva porque la pendiente de la recta de regresión es positiva.

Con base en lo anterior: Se corrobora la teoría económica de que el ingreso determina el consumo.

En Excel podemos calcular el coeficiente de correlación con el comando:

=COEF.DE.CORREL(matriz1; matriz2)

Donde:

matriz1 son los valores de la columna de X

matriz 2: valores columna Y

SUMA ✖ ✓ f_x =COEF.DE.CORREL(H12:H15;I12:I15)							
	E	F	G	H	I	J	K
9							
10							
11			Año	X	Y		
12			1	5	3		
13			2	6	4		
14			3	8	5		
15			4	9	8		
16							
17			r	=COEF.DE.CORREL(H12:H15;I12:I15)			
18							
19							

Año	X	Y
1	5	3
2	6	4
3	8	5
4	9	8
r		0,93

¿Qué es lo que tenemos que saber de la correlación?

- La correlación indica el grado de relación lineal entre 2 variables numéricas
- No tiene unidades y puede tener valores entre -1 y 1.
- El signo positivo indica relación lineal creciente.
- El signo negativo indica relación lineal decreciente.
- Si la correlación es 0 significa que las variables NO tienen ninguna relación lineal.

Un valor de r de 0.93 como el del ejemplo, nos indica que la relación entre las variables es fuerte y positiva.

En tal sentido, podemos emplear el modelo lineal con confianza para hacer pronósticos. A partir de 0.8 o -0.8 se puede decir que la relación es ALTA.

De 0.6 a 0.7. o -0.6 a -0.7. relación moderada.


Es decir que mientras más cerca de 1 o -1 esté nuestro coeficiente de correlación, mayor es la correlación entre nuestras variables.

Pero ¿En qué magnitud, que porcentaje de los cambios en Y son explicados por los cambios en la variable X? La respuesta se obtiene calculando el **coeficiente de determinación**.

El mismo se denota con $R^2 = r^2$

En nuestro caso el coeficiente de determinación es $R^2 = 0.93^2 = 0.86$

Este valor sale del mismo gráfico, o podemos calcularlo utilizando el comando:
=COEFICIENTE.R2(conocido y; conocido x)



Esto nos dice que el 86% de la variabilidad total en la variable Consumo puede ser

explicada por la variable ingresos, en consecuencia, es una medida de la capacidad de predicción del modelo.

El R^2 nos indica la bondad de ajuste, es decir qué tan bueno es nuestro modelo para predecir. Mientras más cercano a 1 sea el valor de R^2 , mejor serán nuestras predicciones.


4. ANÁLISIS DE RESIDUOS

Una desventaja del método de cuadrados mínimos es que observaciones con X muy grande o muy pequeño que caigan lejos de la tendencia del resto de los datos pueden modificar sustancialmente la estimación.

Una observación se denomina **influyente** si al excluirla la recta de regresión estimada cambia notablemente.

Por ejemplo tenemos las variables: X: Experiencia laboral (en años)

Y: Salario (miles de pesos)



cta estimada	Coefficiente de Determinación r^2
$y = 29.5988 - 0.5393 * X$	0.01196 con dato influyente
$y = 7.8215 - 1.3920 * X$	0.9777 sin dato influyente

Un dato influyente puede ser fácilmente detectado a través de métodos gráficos, aunque también existen medidas indicadoras de cuán influyente es una observación.

Cuando detectamos un outlier tan severo, es importante investigarlo. Puede estar mal registrado. Si es correcto, quizás sea diferente de las otras del modo como ocurre en el ejemplo anterior y hay que preguntarse si interesa mantenerlo en el análisis. Si el dato es correcto y no hay razones para excluirlo del análisis entonces la estimación de los parámetros debería hacerse con un método robusto.

DIAGNÓSTICO EN REGRESIÓN

¿Cómo sabemos si el modelo se ajusta razonablemente bien a nuestros datos?

Recordemos nuevamente los supuestos de nuestro modelo lineal.

- Linealidad.
- Distribución normal de la variable Y condicional a X.
- Homocedasticidad.
- Independencia de los errores.


En la práctica es imposible verificar que los supuestos se cumplen. La idea es averiguar si existen apartamientos groseros de alguno de ellos, si no observamos apartamientos groseros entonces el modelo puede todavía ser útil.

Análisis de los residuos

La mayoría de los supuestos puede chequearse usando los residuos $e_i = Y_i - \hat{Y}_i$. Representan la distancia de cada observación a la recta ajustada.

Normalidad. Si las observaciones provienen de distribuciones normales todas con la misma varianza σ , entonces los residuos deberían mostrar una distribución aproximadamente normal. Para chequearlo podemos usar métodos gráficos o el test de Shapiro-Wilk.

Linealidad y homocedasticidad Para chequear que el modelo lineal es una buena aproximación a la verdadera relación entre las variables y para chequear el supuesto de homogeneidad de varianzas usamos el gráfico de residuos versus valores predichos. Si el gráfico muestra una nube de puntos alrededor de cero sin evidencia de estructura, tendencia o cambio de la dispersión, entonces no hay sospecha de que se violen ninguno de estos dos supuestos.



Residuos estandarizados

En el método de mínimos cuadrados los valores de la variable explicativa alejados de su media tienden a acercar la recta hacia ellos, esto se llama efecto palanca. Como consecuencia los residuos tienden a ser menores para valores de X extremos, es decir que si la observación x_i , está lejos de su promedio, la varianza de los residuos será chica y el valor ajustado estará cerca del valor observado por efecto palanca.

Para eliminar esta tendencia **se consideran los residuos estandarizados definidos** por:

$$r_{si} = \frac{e_i}{\sigma * \sqrt{1 - h_{ii}}}$$

Donde:

$$h_{ii} = \frac{1}{n} + \frac{(X_i - \bar{X})^2}{\sum_{k=1}^n (x_k - \bar{x})^2}$$

Es una medida del alejamiento del valor x_i respecto a su media, llamada “**leverage**”

Una observación con residuo grande se denominan dato atípico (outlier), normalmente se considera que una observación es un dato atípico si tiene un residuo estandarizado mayor que 2 ($|r_{si}| > 2$), otras veces se pide que $|r| > 3$. En cualquier caso es una elección subjetiva y cuanto mayor sea $|r_i|$ más atípica es la observación.

BIBLIOGRAFÍA RECOMENDADA

OBLIGATORIA

Richard Levin; David S Rubin. Estadística para Administración y Economía. 7ma Edición. 2004.
Pearson Educación.

COMPLEMENTARIA

Robert D. Mason; Douglas A. Lind. Estadística para Administración y Economía, 8ª edición.
Madrid, Alfaomega grupo editor, 1999

David Levine y Mark L. Berenson. Estadística básica en administración: conceptos y
aplicaciones. Pearson, 1992

Ronald M. Weiers. Introducción a la estadística para negocios, 5ta edición, México.
CENGAGE learning, 2008.