




Estadística – Unidad III

Regresión Lineal

Regresión y Correlación Lineal





Relación de la altura con la edad en niños. Niños de la misma edad seguramente no tendrán la misma altura. Sin embargo, a través de un modelo estadístico es posible concluir que la altura aumenta con la edad. Es más, podríamos predecir la altura de un niño de cierta edad y asociarse un **error de predicción** que tiene en cuenta: **errores de medición y variabilidad entre individuos**.

Regresión y Correlación Lineal



Año	Y	X
1	3	5
2	4	6
3	5	8
4	8	9
N=4		

Y: consumo X: ingreso



*Consumo = $\beta_0 + \beta_1 * Ingreso + error$:*

$$Y_i = \beta_0 + \beta_1 * X_i + \varepsilon_i$$



¿Cuál es mejor?

Residuos = Y observado - Y ajustado

La que minimiza los Residuos

METODO DE MINIMOS CUADRADOS

Ajuste por Mínimos Cuadrados

Buscamos $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimice $e_i = Y_i - \hat{Y}_i$ entonces $\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 * x_i)^2$

$$\frac{\partial}{\partial \hat{\beta}_0} \left(\sum_{i=1}^n e_i^2 \right) = -2 \sum_{i=1}^n (y_i - 1 - \hat{\beta}_1 * x_i) = 0 \longrightarrow \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 * \bar{X}$$


$$\frac{\partial}{\partial \hat{\beta}_1} \left(\sum_{i=1}^n e_i^2 \right) = -2 \sum_{i=1}^n x_i * (y_i - \hat{\beta}_0 - x_i) = 0 \longrightarrow \hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X}) * (Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^4 (X_i - \bar{X}) * (Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{(5 - 7)(3 - 5) + (6 - 7)(4 - 5) + (8 - 7)(5 - 5) + (9 - 7)(8 - 5)}{(5 - 7)^2 + (6 - 7)^2 + (8 - 7)^2 + (9 - 7)^2} = \frac{11}{10} = 1.1$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 * \bar{X} = 5 - 1.1 * 7 = -2.7$$

Ajuste por Mínimos Cuadrados

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 * X_i = -2.7 + 1.1 * X_i$$



Coeficiente de Correlación y Determinación

¿Qué tan bueno es un ajuste ?

Coeficiente R de Pearson

$-1 < R < 1$
Dirección
Grado de la relación

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X}) * (Y_i - \bar{Y})}{n \cdot S_x * S_y}$$

Desviación
estándar
de X

Desviación
estándar
de Y

$$S_x = \sqrt{\frac{\sum_{i=1}^n X_i^2}{N} - \bar{X}^2}$$

$$S_y = \sqrt{\frac{\sum_{i=1}^n Y_i^2}{N} - \bar{Y}^2}$$

Coeficiente de Correlación y Determinación

$$= \frac{\sum_{i=1}^4 (X_i - \bar{X}) * (Y_i - \bar{Y})}{n * S_x * S_y} = \frac{(5 - 7)(3 - 5) + (6 - 7)(4 - 5) + (8 - 7)(5 - 5) + (9 - 7)(8 - 5)}{4 * 1.58 * 1.87} = 0.93$$


$$S_y = \sqrt{\frac{\sum_{i=1}^n Y_i^2}{N} - \bar{Y}^2} = \sqrt{\frac{3^2 + 4^2 + 5^2 + 8^2}{4} - 5^2} = 1.87 \quad S_x = \sqrt{\frac{\sum_{i=1}^4 X_i^2}{N} - \bar{X}^2} = \sqrt{\frac{5^2 + 6^2 + 8^2 + 9^2}{4} - 7^2} = 1.58$$

Coeficiente de
Determinación:

$$\nearrow R^2 = r^2 \longrightarrow R^2 = 0.93^2 = 0.86 \searrow$$

**86 % de la variación se
explica el ajuste de
mínimos cuadrados**

Gráficos de Residuos



Recta estimada	Coeficiente de Determinación r2	
	0.01196	con dato influyente
	0.9777	sin dato influyente

Hay que investigarlo

Hay que Investigar los supuestos del Modelo

- Linealidad
- Distribución Normal de Y condicional a X
- Homedasticidad
- Independencia de los errores

Todos esto se investiga con los residuos

$$e_i = Y_i - \hat{Y}_i$$


Normalidad: gráficos de e y/o test de Shapiro-Wilk

Homedasticidad: gráficos de e vs valores ajustados

Linealidad: gráficos de e vs valores ajustados

Gráficos de Residuos

ninguno de estos dos supuestos.



LEVERA
GE

$$r_{si} = \frac{e_i}{\sigma * \sqrt{1 - h_{ii}}}$$

$$h_{ii} = \frac{1}{n} + \frac{(X_i - \bar{X})^2}{\sum_{k=1}^n (x_k - \bar{x})^2}$$



En el método de mínimos cuadrados los valores de la variable explicativa alejados de su media tienden a acercar la recta hacia ellos, esto se llama efecto palanca. Como consecuencia los residuos tienden a ser menores para valores de X extremos, es decir que si la observación x_i , está lejos de su promedio, la varianza de los residuos será chica y el valor ajustado estará cerca del valor observado por efecto palanca.

¡Gracias!