

Estadística – Unidad III

Regresión Lineal

Regresión y correlación Lineal



Vamos a hablar de predicciones

Vamos a aprender a crear una función matemática para predecir una variable numérica en función de la otra.

¿para qué puede servir?

- Para predecir la frecuencia cardíaca máxima según la edad, el peso y la altura de los pacientes
- Para predecir el número de arrestos en los próximos años.
- Para predecir la cantidad de ventas según el precio del producto

¿Qué es un modelo de predicción?


Los ejemplos que citamos antes nacen del impulso del cálculo de un modelo. Y usarlo para la predicción

Un modelo te permite entender la realidad con una función matemática. Esta puede ser tan complicada como se quiera.

De modelos se pueden hacer los que quieras y más. Unos de los más complicados son los modelos de predicción meteorológica. Cantidades de variables que se relacionan de manera muy compleja.

Pero todo modelo nace del mismo impulso: **la predicción.**

Regresión y Correlación Lineal



Relación de la altura con la edad en niños. Niños de la misma edad seguramente no tendrán la misma altura. Sin embargo, a través de un modelo estadístico es posible concluir que la altura aumenta con la edad. Es más, podríamos predecir la altura de un niño de cierta edad y asociarle **un error de predicción** que tiene en cuenta: **errores de medición y variabilidad entre individuos**.

¿Cómo calcular el modelo más simple: la recta de regresión lineal?

Un modelo no es más que una función matemática que se calcula gracias a datos que se observan. Y después se utiliza esta función matemática para predecir nuevos datos.

El análisis de regresión lineal consiste en encontrar un modelo lineal.

Una función matemática. La función de una recta.

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 * X_i + e$$

Donde: $\hat{\beta}_1$ es la pendiente de la recta y $\hat{\beta}_0$ la ordenada al origen (donde la recta corta al eje vertical)

El análisis de regresión involucra el estudio de la relación entre dos variables *cuantitativas*.

En general interesa:

- Investigar si existe una asociación entre las dos variables testeando la hipótesis de independencia estadística.
- Estudiar la fuerza de la asociación, a través de una medida de asociación denominada coeficiente de correlación.
- Estudiar la forma de la relación.

Regresión y Correlación Lineal




Año	Y	X
1	3	5
2	4	6
3	5	8
4	8	9
N=4	$\bar{Y} = 5$	$\bar{X} = 7$

Y: consumo X: ingreso



$$\text{Consumo} = \beta_0 + \beta_1 * \text{Ingreso} + \text{error:}$$

$$Y_i = \beta_0 + \beta_1 * X_i + \varepsilon_i$$



¿Cuál es mejor ?

Residuos = Y observado – Y ajustado


La que minimiza los Residuos

METODO DE MINIMOS CUADRADOS

Diagrama de puntos

Lo primero es dibujar los puntos en un gráfico. Y determinar si los puntos siguen una tendencia lineal (creciente o decreciente). Si esto es así podemos intentar dibujar la recta que mejor explique los puntos del gráfico. O, dicho de otro modo, que mejor explique el comportamiento de los datos.

Diagrama de Dispersión



Se observa que el diagrama de dispersión de la figura sugiere una relación lineal con pendiente positiva.

Ajuste por Mínimos Cuadrados

Buscamos valores de $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimicen $e_i = Y_i - \hat{Y}_i$ entonces $\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 * x_i)^2$

$$\frac{\partial}{\partial \hat{\beta}_0} \left(\sum_{i=1}^n e_i^2 \right) = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 * x_i) = 0 \longrightarrow \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 * \bar{X}$$


$$\frac{\partial}{\partial \hat{\beta}_1} \left(\sum_{i=1}^n e_i^2 \right) = -2 \sum_{i=1}^n x_i * (y_i - \hat{\beta}_0 - \hat{\beta}_1 * x_i) = 0 \longrightarrow \hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X}) * (Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^4 (X_i - \bar{X}) * (Y_i - \bar{Y})}{\sum_{i=1}^4 (X_i - \bar{X})^2} = \frac{(5-7)(3-5) + (6-7)(4-5) + (8-7)(5-5) + (9-7)(8-5)}{(5-7)^2 + (6-7)^2 + (8-7)^2 + (9-7)^2} = \frac{11}{10} = 1.1$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 * \bar{X} = 5 - 1.1 * 7 = -2.7$$

Ajuste por Mínimos Cuadrados

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 * X_i = -2.7 + 1.1 * X_i$$



COEFICIENTE DE CORRELACIÓN Y DETERMINACIÓN

La **correlación** es el indicador para saber si hay relación lineal entre dos variables numéricas es el coeficiente de correlación o correlación de Pearson

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X}) * (Y_i - \bar{Y})}{n * S_x * S_y}$$

Es un coeficiente que varía entre -1 y 1. Si su valor es cercano a cero, indica la inexistencia de correlación.

Coeficiente de Correlación y Determinación

¿Qué tan bueno es un ajuste ?

Coeficiente R de Pearson

$$-1 < R < 1$$

Dirección

Grado de la relación

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X}) * (Y_i - \bar{Y})}{n \cdot S_x * S_y}$$

Desviación
estándar de X

Desviación
estándar de Y

$$S_x = \sqrt{\frac{\sum_{i=1}^n X_i^2}{N} - \bar{X}^2}$$

$$S_y = \sqrt{\frac{\sum_{i=1}^n Y_i^2}{N} - \bar{Y}^2}$$

Qué es lo que tienes que saber de la correlación:

- La correlación indica el grado de relación lineal entre 2 variables numéricas
- No tiene unidades y puede tener valores entre -1 y 1.
- El signo positivo indica relación lineal creciente.
- El signo negativo indica relación lineal decreciente.
- Si la correlación es 0 significa que las variables NO tienen ninguna relación lineal.

¿En qué magnitud, que porcentaje de los cambios en Y son explicados por los cambios en la variable X? La respuesta se obtiene calculando **el coeficiente de determinación.**

El mismo se denota con $R^2 = r^2$

Coeficiente de Correlación y Determinación


$$= \frac{\sum_{i=1}^4 (X_i - \bar{X}) * (Y_i - \bar{Y})}{n * S_x * S_y} = \frac{(5 - 7)(3 - 5) + (6 - 7)(4 - 5) + (8 - 7)(5 - 5) + (9 - 7)(8 - 5)}{4 * 1.58 * 1.87} = 0.93$$

$$S_y = \sqrt{\frac{\sum_{i=1}^n Y_i^2}{N} - \bar{Y}^2} = \sqrt{\frac{3^2 + 4^2 + 5^2 + 8^2}{4} - 5^2} = 1.87$$

$$S_x = \sqrt{\frac{\sum_{i=1}^4 X_i^2}{N} - \bar{X}^2} = \sqrt{\frac{5^2 + 6^2 + 8^2 + 9^2}{4} - 7^2} = 1.58$$

Coeficiente de Determinación: $\longrightarrow R^2 = r^2 \longrightarrow R^2 = 0.93^2 = 0.86 \longrightarrow$ **86 % de la variación la explica el ajuste de mínimos cuadrados**

Gráficos de Residuos



Recta estimada	Coeficiente de Determinación r^2
$y = 29.5988 - 0.5393 * X$	0.01196
$y = 7.8215 - 1.3920 * X$	0.9777

con dato
influyente
sin dato
influyente

Hay que investigarlo

Hay que Investigar los supuestos del Modelo


- Linealidad
- Distribución Normal de Y condicional a X
- Homedasticidad
- Independencia de los errores

Todos esto se investiga con los residuos $\longrightarrow e_i = Y_i - \hat{Y}$.

Normalidad: gráficos de e y/o test de Shapiro-Wilk
Homecedasticidad: gráficos de e vs valores ajustados
Linealidad: gráficos de e vs valores ajustados

Gráficos de Residuos

ninguno de estos dos supuestos.



LEVERAGE

$$r_{si} = \frac{e_i}{\sigma * \sqrt{1 - h_{ii}}}$$



$$h_{ii} = \frac{1}{n} + \frac{(X_i - \bar{X})^2}{\sum_{k=1}^n (x_k - \bar{x})^2}$$

En el método de mínimos cuadrados los valores de la variable explicativa alejados de su media tienden a acercar la recta hacia ellos, esto se llama efecto palanca. Como consecuencia los residuos tienden a ser menores para valores de X extremos, es decir que si la observación x_i , está lejos de su promedio, la varianza de los residuos será chica y el valor ajustado estará cerca del valor observado por efecto palanca.