

¿Cómo calcular el modelo más simple: la recta de regresión lineal?

Un modelo no es más que una función matemática que se calcula gracias a datos que se observan. Y después se utiliza esta función matemática para predecir nuevos datos.

El análisis de regresión lineal consiste en encontrar un modelo lineal. Una función matemática. La función de una recta.

Es decir, encontrar la mejor función de la recta que permita predecir el valor de una variable sabiendo los valores de otra variable que se observa.


la ecuación de una recta tiene esta forma:

$$y = a \cdot x + b$$

Donde: **a** es la pendiente de la recta y **b** donde la recta corta al eje vertical.

Diagrama de puntos

Lo primero es dibujar los puntos en un gráfico. Y determinar si los puntos siguen una tendencia lineal (creciente o decreciente). Si esto es así podemos intentar dibujar la recta que mejor explique los puntos del gráfico. O, dicho de otro modo, que mejor explique el comportamiento de los datos.




En el gráfico anterior observamos que a medida el tiempo se incrementa, también se incrementan los arrestos. Más aún, pareciera existir una relación lineal entre las dos variables (años y número de arrestos). En tal sentido, continuamos con los cálculos de la recta o línea de tendencia.

La regresión trata de calcular **a** y **b** para construir la recta más coherente con los datos que tenemos.

¿Cuál será la recta que mejor explique los datos? Podemos dibujar miles. Y todas parecidas. ¿Cuál escoger?

El análisis de regresión se encarga de dibujar la recta con el **error mínimo**, es decir la recta que tiene la suma de distancias más pequeña de todas las rectas posibles, la que mejor aproxima los puntos.



En este caso la recta (modelo) hallada es: $y = 577.95.x + 658.96$

Esta recta nos permitirá hacer predicciones para los años 9 y 10 en adelante.

Ahora ¿cómo sabemos si nuestro modelo es bueno, es decir, que hará buenas predicciones?

Para ello debemos calcular y analizar el coeficiente de correlación lineal

La relación lineal entre dos variables: la correlación

La **correlación** es el indicador para saber si hay **relación lineal** entre dos variables numéricas es el coeficiente de correlación o correlación de Pearson.

De forma gráfica estas relaciones se observan así:





Qué es lo que tienes que saber de la correlación:

- La correlación indica el grado de relación lineal entre 2 variables numéricas
- No tiene unidades y puede tener valores entre -1 y 1.
- El signo positivo indica relación lineal creciente.
- El signo negativo indica relación lineal decreciente.
- Si la correlación es 0 significa que las variables NO tienen ninguna relación lineal.

Un valor de r de 0.97 nos indica que la relación entre las variables es fuerte y positiva. En tal sentido, podemos emplear el modelo con confianza para pronosticar hacer pronósticos.

A partir de 0.8 o -0.8 se puede decir que la relación es ALTA.

De 0.6 a 0.7. o -0.6 a -0.7. relación moderada

Es decir que mientras más cerca de 1 o -1 esté nuestro coeficiente de correlación, mayor es la relación entre nuestras variables.

Ejemplo en En Excel:

El sistema carcelario de nuestra jurisdicción tiene una capacidad máxima de 7.000 plazas. Considerando los lapsos de tiempo requeridos para ampliar las cárceles o inclusive construir una nueva, se quiere predecir en cuántos años se alcanzará el máximo de la capacidad del sistema carcelario a partir de la presente fecha, en base a la cantidad de arrestos de los últimos 8 años.

Tenemos los datos en la siguiente tabla:

AÑOS	Nº DE ARRESTOS
1	1374
2	2132
3	2466
4	2604
5	3025
6	3778
7	5212
8	5487
9	
10	

1) Calculamos el coeficiente de correlación:

Hacemos click en fórmulas -> Más funciones -> Hacemos click en estadísticas->

COEF.DE.CORREL(Cargamos los datos de las variables)

Para estos datos obtuvimos **r: 0.97**

Como es mayor a 0.8, podemos usar los datos para predecir la cantidad de arrestos en los años 9 y 10

2) Calculamos con la fórmula de tendencia la cantidad de arrestos para el año 9.

Hacemos click en el recuadro de fórmulas -> click en más funciones-> click en estadísticas-> click en **tendencias**

Procedemos a llenar los datos. Los valores de las columnas X(años) e Y (número de arrestos), **en el número de matriz colocamos el año 9 que estamos buscando.(En constantes nada, lo dejamos en blanco.)**

Obtenemos 5.860,51 arrestos para el año 9 y lo redondeamos a 5.861.

- 3) Con el dato obtenido del año 9, llenamos nuevamente el cuadro de tendencia para calcular el año 10, damos Aceptar. Redondeamos a 6438
- 4) Aplicamos la fórmula de Error Estándar de Estimación para los dos años de pronóstico (9 y 10).

Error estándar año 9: Hacemos click en el recuadro de fórmulas -> click en más funciones-> click en estadísticas->**error típico xy** obtenemos 399 redondeando.

El primer error estándar de la estimación nos da un 68% de probabilidad de certeza para el pronóstico. Tenemos:

$$5.861 \text{ (arrestos pronosticados año 9)} + 399 = 6.260 \text{ arrestos}$$

$$5.861 \text{ (arrestos pronosticados año 9)} - 399 = 5.462 \text{ arrestos}$$

Nuestro intervalo de confianza de arrestos para el año 9, está entre 5.462 y 6.260 arrestos.

Para alcanzar un 95% de certeza en el pronóstico, simplemente multiplicamos el primer error estándar por 2, es decir $2 \times (+ 399) = + 798$, y se lo sumamos y restamos a 5.861 arrestos, de la siguiente forma:

$$5.861 \text{ (arrestos pronosticados año 9)} + 798 = 6.659 \text{ arrestos}$$

$$5.861 \text{ (arrestos pronosticados año 9)} - 798 = 5.063 \text{ arrestos}$$

Error estandar año 10: Hacemos click en el recuadro de fórmulas -> click en más funciones-> click en estadísticas->**error típico xy** obtenemos 345 redondeando

El primer error estándar de la estimación nos da un 68% de probabilidad de certeza para el pronóstico. Tenemos:

$6438 \text{ (arrestos pronosticados año 10)} + 345 = 6783 \text{ arrestos}$

$6438 \text{ (arrestos pronosticados año 10)} - 345 = 6093 \text{ arrestos}$

Nuestro intervalo de confianza de arrestos para el año 10 está entre 6093 y 6783 arrestos. (con un 68% de certeza)

Para alcanzar un 95% de certeza en el pronóstico, simplemente multiplicamos el primer error estándar por 2, es decir $2 \times (+ 345) = + 690$, y se lo sumamos y restamos a 6438 arrestos, de la siguiente forma:

$6438 \text{ (arrestos pronosticados año 10)} + 690 = 7128 \text{ arrestos}$

$6438 \text{ (arrestos pronosticados año 9)} - 690 = 5748 \text{ arrestos}$


Nuestro intervalo de confianza de arrestos para el año 10 con un 95% de certeza, esta entre 5748 y 7128 arrestos.

Conclusión: con un 95% de certeza pronosticamos que para el año 10 la capacidad del sistema carcelario (de 7000 plazas) se verá colapsada.

Para hacer el gráfico:

1. Seleccionamos la tabla -> Hacemos click en insertar -> gráfico dispersión -> aceptar
2. **Nos posicionamos en el grafico de puntos** obtenidos hacemos clic en -> elemento de grafico -> linea de tendencia elegimos lineal -> mas opciones de linea de tendencia / al final marcamos presentar ecuacion en el gráfico y presentar valor de r cuadrado en el grafico

El r cuadrado nos dice el nivel de ajuste de nuestro modelo, si es cercano a 1, nuestro modelo es bueno.



Podemos usar la recta de tendencia para calcular los valores para los año 9 y 10, simplemente reemplazando en $x = 9$, haciendo la cuenta hallaríamos el mismo valor que usando la función tendencia del excel.